

Ψηφιακή Επεξεργασία Εικόνας

Παπαδόπουλος Ιωάννης-Ραφαήλ AEM:10696

Περίληψη

Τμηματοποίηση Εικόνας

1 Εισαγωγή

Στην εργασία αυτή ασχολούμαστε με την αναπαράσταση εικόνας ως γράφου και την τμηματοποίηση της με τις μεθόδους *spectral clustering* και *n - cuts* (αναδρομική και μη).

2 Εικόνες ως Γράφοι

Η πρώτη συνάρτηση που υλοποιούμε είναι η *image - to - graph* η οποία δέχεται ως όρισμα μια εικόνα με C κανάλια και επιστρέφει τον *affinity matrix* που περιγράφει τον μη κατευθυντικό γράφο $G = (V, E)$. Αρχικά ορίζουμε τους κόμβους, καθέναν εκ των οποίων αναπαριστά ένα *pixel* της εικόνας και υπολογίζουμε την Ευκλείδεια απόσταση της φωτεινότητας μεταξύ όλων των κόμβων ($d(i, j)$). Το βάρος της κάθε ακμής υπολογίζεται ως $e^{-d(i, j)}$. Από την φύση της Ευκλείδειας απόστασης και την μορφή της συνάρτησης ομοιότητας $A(i, j)$ προκύπτει πως ο πίνακας *affinity* θα είναι *fully - connected* με μη-μηδενικό βάρος για κάθε ακμή και επίσης πως θα είναι τετράγωνος και συμμετρικός.

3 Spectral Clustering

Η επόμενη συνάρτηση που δημιουργούμε είναι η *spectral-clustering*, η οποία δέχεται τον *affinity* πίνακα που περιγράφει τον μη-κατευθυντικό γράφο και τον αριθμό των *clusters* που επιθυμούμε και επιστρέφει τα *labels* των *clusters* στις οποίες ανήκουν οι κορυφές του γράφου. Αρχικά ακολουθούμε τα βήματα της εκφώνησης ορίζοντας κατάλληλα τους πίνακες D και L . Υπολογίζουμε τα ιδιοδιανύσματα και τις ιδιοτιμές. Για τον υπολογισμό αυτών αντί της συνάρτησης *eigs* έγινε χρήση της *eigsh* αφού σύμφωνα με το *documentation* η συνάρτηση αυτή είναι κατάλληλη για συμμετρικούς πίνακες (όπως εδώ) και ερμιτιανούς και είναι λιγότερο χρονοβόρα. Επίσης υπολογίζουμε μονάχα τις k μικρότερες ($SM = SmallMagnitude$) ιδιοτιμές και αντίστοιχα ιδιοδιανύσματα. Τέλος εφαρμόζουμε την συνάρτηση *k - means* στα δεδομένα του πίνακα U και παίρνουμε ως αποτέλεσμα τα *labels*.


4 Προετοιμασία

Για να έχουμε μια πλήρη γνώση σχετικά με τις εικόνες που δοθήκαν και να μπορούμε να σχολιάζουμε τα αποτελέσματα τις προβάλλουμε. Τα αποτελέσματα φαίνονται στο Σχήμα 1.

5 Demo 1

Στο πρώτο *demo* καλούμαστε να δοκιμάσουμε τις λειτουργίες της παραπάνω συνάρτησης σε έναν προκατασκευασμένο πίνακα *affinity* dla για *spectral clustering* με τις τιμές κέντρων $k=2,3,4$. Αρχικά φορτώνουμε τα δεδομένα ως *affinity matrix* και φτιάχνουμε ένα *custom ColorMap* με 4 διαφορετικά χρώματα (αφού το k παίρνει το πολύ την τιμή 4) και καλούμε την ρουτίνα *spectral clustering* για τις ζητούμενες τιμές. Τα ενδεικτικά αποτελέσματα βρίσκονται στο Σχήμα 2. Από τα αποτελέσματα βλέπουμε πως πράγματι για κάθε επιλογή του k η εικόνα διαχωρίζεται σε k διαφορετικές χρωματικές περιοχές. Να σημειωθεί ωστόσο πως στο *demo* αυτό όσο και στα υπόλοιπα το χρώμα που εμφανίζεται ως αποτέλεσμα

δεν έχει ουδεμία σύνδεση με το πραγματικό χρώμα του κάθε *pixel* άλλα αντιπροσωπεύει απλώς το κάθε διαφορετικό *cluster label*.



Σχήμα 1: Οι εικόνες προς πειραματισμό

6 Demo 2




Στο δεύτερο *demo* καλούμαστε να χρησιμοποιήσουμε αμφότερες τις δύο συναρτήσεις που υλοποιήσαμε για να δοκιμάσουμε την λειτουργίες του. Μας δίνονται δύο *RGB* εικόνες με ονόματα *d2a* και *d2b*. Αρχικά φορτώνουμε τις εικόνες και εκτελούμε το *pipeline* στο οποίο πρώτα μετατρέπουμε την εικόνα σε γράφο μέσω της *image-to-graph* και ύστερα στο αποτέλεσμα, δηλαδή στον *affinity matrix* εφαρμόζουμε την *k-means* για τιμές του $k=2,3,4$ και για τις δύο εικόνες εισόδου. Τα αποτελέσματα βρίσκονται στο Σχήμα 3. Από τα αποτελέσματα μπορούμε να συμπεράνουμε πως αρχικά για την εικόνα *d2a* η οποία αποτελείται από 3 διακριτές περιοχές με κόκκινο, πράσινο και μπλε όταν καλούμε το $k=2$ τότε αναγκαστικά θα ενωθούν κάποια διακριτά χρώματα σε κοινό *cluster* και θα χάσουμε λεπτομέρεια. Στην περίπτωση που το $k=3$ η τμηματοποίηση έγινε άψογα, ενώ όταν το $k=4$ η συνάρτηση 'σπάει' περιοχές που δεν θα έπρεπε και για αυτό εμφανίζεται και ένα τέταρτο μη-επιθυμητό ιδανικά *cluster*. Στην περίπτωση της εικόνας *d2b* όπου τα διαφορετικά χρώματα που υπάρχουν στην αρχική εικόνα είναι πάρα πολλά με την αύξηση του k από 2 έως και 4 δεν θα έχουμε κάποιο πρόβλημα και απλώς σε κάθε αύξηση θα αυξάνουμε την λεπτομέρεια και την 'διακριτική' ικανότητα του αλγορίθμου βρίσκοντας ολοένα και περισσότερες διαφορετικές περιοχές πάνω στην εικόνα. Επίσης επιβεβαιώνουμε ότι λόγω του *affinity matrix* δεν έχουμε ως κριτήριο την χωρική πληροφορία αλλά μόνο την χρωματική και έτσι ανιχνεύονται τα παρόμοια χρώματα ως ίδιο *cluster* ανεξάρτητα με την θέση τους στην εικόνα.

7 Normalized Cuts


Η τελευταία συνάρτηση προς υλοποίηση είναι η *normalized cuts* με δύο εκδοχές, την αναδρομική και την μη. Αρχικά δημιουργούμε την μη-αναδρομική εκδοχή στην συνάρτηση $n - cuts$ με την υλοποίηση να ακολουθεί την διαδικασία της εκφώνησης και να μοιάζει πολύ με αυτήν της μεθόδου *Spectral Clustering* με την διαφορά να έγγειται στο γενικευμένο πρόβλημα των ιδιοτιμών που καλούμαστε να λύσουμε στην περίπτωση αυτή, για αυτό και αλλάζουμε κατάλληλα τα ορίσματα κατά την κλήση της *eigsh* (ο πίνακας είναι πάλι συμμετρικός).

8 Τιμή της Μετρικής $N - cut$

Υστερα υλοποιούμε την συνάρτηση *calculate - n - cut - value* η οποία υπολογίζει την τιμή της μετρικής $n - cut$ όπως ορίζεται στην εκφώνηση. Υπολογίζουμε όλα τα απαραίτητα *assoc* μεταξύ των ομάδων κόμβων και ακολουθώντας τις εξισώσεις που δόθηκαν η συνάρτηση επιστρέφει το $n - cut$ που εκφράζει πόσο 'σχέση' χάνουμε αν διαχωρίσουμε έναν γράφο σε δύο υποομάδες.



Σχήμα 2: (demo 1) *Spectral Clustering* για $k=2,3,4$



Σχήμα 3: (demo 2) Image to graph και spectral clustering

9 Αναδρομική $N - cuts$

Η τελευταία προς υλοποίηση συνάρτηση είναι η $n - cuts - recursive$ η οποία προχωρά σε διαδοχική διχοτόμηση του γράφου σε δύο κομμάτια έχοντας ως κριτήριο τερματισμού τις τιμές T_1 και T_2 . Εάν ο αριθμός κόμβων κάποιας ομάδας είναι μικρότερος από T_1 ή εάν η τιμή $Ncut(A, B)$ είναι μεγαλύτερη από T_2 τότε η διχοτόμηση σταματά, αλλιώς επαναλαμβάνεται αναδρομικά. Η πρώτη συνθήκη αυτή εξασφαλίζει πως η διχοτόμηση δεν θα διαιρέσει τον γράφο σε πολύ μικρά *clusters* ενώ η δεύτερη πως δεν θα σπάσουμε κάποια καλά συνδεδεμένα πιθανά κομμάτια. Στην υλοποίηση της συνάρτησης αυτής αποδίδουμε *labels* μονάχα στα φύλλα του *unbalanced* δέντρου έτσι ώστε να αποφύγουμε συγχύσεις από διπλό *label*.

10 Demo 3

Στο *demo* αυτό δοκιμάζουμε τις παραπάνω συναρτήσεις στις εικόνες *d2a* και *d2b*. Από εδώ και στο εξής ως *ColorMap* θα χρησιμοποιούμε το έτοιμο *tab20* για λόγους ευκολίας αναπαράστασης των πολλών πιθανώς *clusters*.

11 Demo 3a

Αρχικά κατασκευάζουμε τους *affinity matrices* των εικόνων και καλούμε την μη-αναδρομική εκδοχή της $n - cuts$ για αριθμούς κέντρων $k=2,3,4$ και για τις δύο εικόνες. Τα αποτελέσματα φαίνονται στο Σχήμα 4. Επίσης για λόγους σύγκρισης δίπλα σε κάθε εικόνα στην οποία έχει εφαρμοστεί η $n - cuts$ υπάρχουν και τα αντίστοιχα αποτελέσματα από την διαδικασία *spectral clustering*. Όπως φαίνεται για τις καλά διαχωρίσιμες περιοχές όπως στην εικόνα *d2a* τα αποτελέσματα είναι τα ίδια (και έχουμε το ίδιο 'πρόβλημα' με προηγουμένως για $k=4$). Για την εικόνα *d2b* ωστόσο η μέθοδος $n - cuts$ αυξάνει αρκετά την αποτελεσματικότητα για όλες τις τιμές του k . Αυτό ήταν αναμενόμενο αφού η *spectral clustering*


χαλαρώνει το πρόβλημα (*relaxation*) όπως φάνηκε και από την διαφορά στο γενικευμένο πρόβλημα των ιδιοτιμών.

12 Demo 3b


Στο επόμενο *demo* δημιουργούμε και πάλι τους γράφους εισόδου και εκτελούμε την αναδρομική $n - cuts$ για ένα βήμα, δηλαδή σπάμε τον γράφο σε 2 κομμάτια. Τα αποτελέσματα φαίνονται στο Σχήμα 5. Οι τιμές $n - cut$ είναι 0.5 στην πρώτη περίπτωση και 0.78 στην δεύτερη. Το ότι η τιμή στην πρώτη περίπτωση είναι μικρότερη επιβεβαιώνει πως ο διαχωρισμός ήταν πιο φυσικός (αναμενόμενο με βάση την δομή της εικόνας), ενώ στην δεύτερη εικόνα που τα αντικείμενα ήταν πιο 'συνεχόμενα' κόπηκαν περισσότερες πιθανές συνδέσεις. Επίσης και σε αυτήν την περίπτωση φαίνεται πως τα αποτελέσματα είναι παρόμοια με αυτά της *spectral clustering* με $k = 2$ για την πρώτη εικόνα και καλύτερα όσον αφορά την δεύτερη.

13 Demo 3c


Στο τελευταίο *demo* καλούμαστε να παρουσιάσουμε την αναδρομική εκτέλεση της μεθόδου $n - cuts$ για κατώφλια $T_1=5$ και $T_2=0.2$. Για τις τιμές αυτές δεν πραγματοποιούνταν κανένας διαχωρισμός (αναμενόμενο αν αναλογιστούμε ότι οι τιμές $n - cut$ που βρήκαμε στο προηγούμενο *demo* ήταν 0.5 και 0.78) οπότε κρατώντας το T_1 σταθερό στην δοθείσα τιμή θα αλλάξουμε το T_2 και θα σχολιάσουμε την επίδραση που έχει για άλλες τιμές που δίνουν ουσιαστικά αποτελέσματα. Συγκεκριμένα θα δώσουμε στο κατώφλι T_2 τις τιμές 0.9 και 0.95 αντίστοιχα. Τα αποτελέσματα φαίνονται στο Σχήμα 6. Για τις τιμές 0.9 και 0.95 η πρώτη εικόνα διαχωρίστηκε στις 3 επιθυμητές περιοχές. Για τις ίδιες τιμές η δεύτερη εικόνα διαχωρίστηκε σε πολλά *clusters*, με τον αριθμό αυτών να αυξάνει όσο αυξάνει η τιμή του T_2 . Για μεγαλύτερες τιμές ωστόσο κοντά στο 1 έχουμε *overfitting* και ακόμα και μικρές διαφοροποιήσεις ή θόρυβος ανιχνεύονται ως διαφορετικό *cluster*. Το αποτέλεσμα για 0.95 φαίνεται να αποφέρει μια πολύ καλή τμηματοποίηση τόσο για την πρώτη εικόνα (η οποία λόγω της δομής της θα είχε τα ίδια αποτελέσματα και για μικρότερο T_2) όσο και για την δεύτερη η οποία περιέχει πολλά χρωματικά *clusters* όπως φαίνεται από την *original* εικόνα. Τα αποτελέσματα αυτά είναι σαφώς καλύτερα από αυτά της μη-αναδρομικής $n - cuts$ και από του *spectral clustering*, διότι χωρίζει αναδρομικά και ελέγχει το νέο *normalized cut* σε κάθε επανάληψη.



Σχήμα 4: (demo 3a) Μη Αναδρομική n – cuts για $k=2,3,4$ και σύγκριση με *spectral clustering* (δεξιά)



Σχήμα 5: (demo 3b) Αναδρομική $n - cut$ για ένα βήμα



Σχήμα 6: (demo 3c) Αναδρομική Εκτέλεση της $n - cuts$ για συγκεκριμένα κατώφλια